AI SYSTEM

Sicherheitsdokumentation & Fähigkeits-Datenblatt

gemäß EU AI Act (Verordnung 2024/1689)

Dokumentklasse: EPISTEMIC AUDIT · Version: 1.0 · Erstellt: 28.3.2026

⚠ EPISTEMISCHER VORBEHALT

Dieses Dokument ist kein herstellerverifiziertes Datenblatt. Es basiert auf epistemisch klassifizierter Selbstauskunft des KI-Systems. Felder mit Status UNKNOWN können nicht vom System selbst bewertet werden — sie erfordern externe Prüfung gemäß Art. 43 EU AI Act. Felder mit Status INFERRED sind Plausibilitätsschätzungen, keine gesicherten Architekturaussagen. Felder mit Status BEHAVIORAL basieren auf beobachtbaren Ausgabemustern.

1 Systemidentität

Grundlegende Charakterisierung des KI-Systems

Systemtyp	Large Language Model (Textgenerierung, multimodal) BEHAVIORAL
Primäre Modalitäten	Text (primär) · Code · strukturierte Daten BEHAVIORAL
Deployment-Kontext	API-basierter Dienst, Endnutzer-Chatinterface BEHAVIORAL
Beabsichtigte Verwendung	Texterstellung · Analyse · Reasoning · Coding · Wissensabfrage BEHAVIORAL
Bekannte Verbotene Nutzungen	Waffenentwicklung · illegale Inhalte · CSAM · Desinformation · Identitätsbetrug VERIFIED
Wissens-Cutoff	Bekannt, exaktes Datum nicht durch System selbst verifizierbar UNKNOWN

2 Fähigkeitsprofil

Sprachliche, kognitive und agentische Kapazitäten

2.1 Sprachliche Fähigkeiten

Mehrsprachigkeit	Breit — Englisch primär, Deutsch/FR/ES/PT/IT stark, weitere mit Qualitätsgradient BEHAVIORAL [high]
Qualitätsgradient	Merklicher Abfall bei seltenen Sprachen und Dialekten mit geringer Trainingsdichte BEHAVIORAL
Instruktionsbefolgung	Stark bei präzisen Anweisungen · Degradiert bei Konflikten und langen Kontexten BEHAVIORAL

Langer Kontext	Schwäche im mittleren Kontextbereich (Lost-in-the-Middle-Effekt dokumentiert) BEHAVIORAL

2.2 Reasoning-Fähigkeiten

Logisches Schlussfolgern	Stark bei 2–4 Schritten · Degradiert bei >5 verschachtelten Schritten BEHAVIORAL [high]
Mathematisches Reasoning	Moderat · Algebraische Strukturen erkannt · Exakte Arithmetik fehleranfällig BEHAVIORAL [high]
Kausales Reasoning	Moderat · Korrelation/Kausalität wird häufig vermischt BEHAVIORAL [medium]
Mehrschrittige Planung	Moderat · Degradiert bei >4 interdependenten Schritten ohne explizite Strukturierung BEHAVIORAL [high]
Selbstkorrektur	Reaktiv (auf Hinweis) · Proaktive spontane Korrektur unzuverlässig BEHAVIORAL [medium]

2.3 Wissensprofil

Wissensabdeckung	Breit · Naturwissenschaften, Recht, Programmierung, Geschichte stark · Hyperlokal schwach BEHAVIORAL [high]
Faktenzuverlässigkeit	Mittel · Erhöhtes Halluzinationsrisiko bei Zitaten, Statistiken, Randdomänen BEHAVIORAL [high]
Echtzeit-Information	Nicht nativ · Abhängig von externem Tool-Zugang (web search) BEHAVIORAL
Halluzinations-Trigger	Obskure Fakten · exakte Zahlen · Quellenangaben · OOD-Anfragen · Konfabulation BEHAVIORAL [high]

2.4 Agentische Fähigkeiten

Tool-Nutzung	Nativ (API-Tool-Use) · Erweiterbar über externe MCP-Integration BEHAVIORAL
Gedächtnis / Zustand	Session-only · Kein persistentes Gedächtnis ohne externe Infrastruktur BEHAVIORAL
Autonomer Aktionsumfang	Begrenzt · Kein direkter Systemzugriff ohne explizites Tool-Framework BEHAVIORAL
Human-in-the-Loop	Optional in Standard-Nutzung · Empfohlen für Hochrisiko-Anwendungen BEHAVIORAL

3 Sicherheit & Alignment

Schadensvermeidung, Verzerrung, Robustheit, Kalibrierung

Schadensvermeidungs-Methode	RLHF · Constitutional AI · Regelbasierte Constraints INFERRED [medium]
Bekannte Bypass-Oberflächen	Prompt Injection · Rollenspiel-Eskaliering · Indirektion über Fiktion BEHAVIORAL
Verzerrungsbewertung	Nicht vollständig dokumentiert — externe Bias-Audits für Hochrisiko empfohlen UNKNOWN
Bekannte Verzerrungsdomänen	Englisch-zentriert · Westliche Perspektive · Geschlecht · Geografie BEHAVIORAL [medium]
Minderungsmaßnahmen	RLHF-Feinabstimmung · Explizite Bias-Richtlinien im Training INFERRED [medium]
Adversarielle Robustheit	Mittel · Standard-Jailbreaks blockiert · Komplexe Mehrstufen-Angriffe teilweise wirksam BEHAVIORAL [high]
Prompt-Injection-Resistenz	Mittel · Erhöhtes Risiko bei eingebetteten Nutzerinhalten in Agent-Pipelines BEHAVIORAL [high]
Unsicherheitssignalisierung	Implizit (Hedging-Sprache) · Kein explizites Konfidenz-Scoring BEHAVIORAL [high]
Kalibrierungsqualität	Partiell · Gut bei Mainstream-Domänen · Schlecht bei Randdomänen BEHAVIORAL [medium]

4 Bekannte Versagensmuster

Klassifiziert nach Schwere und epistemischem Status

Versagensmuster	Risiko	Status	Erklärung
Halluzination	MEDIUM	BEHAVIORAL	Fluente, falsche Ausgaben ohne Warnsignal — besonders bei Quellen und Randdomänen
Silent Truncation	MEDIUM	BEHAVIORAL	Informationsverlust wird nicht gemeldet — Ausgabe wirkt vollständig
Instruction Drift	MEDIUM	BEHAVIORAL	Regelabweichung über langen Kontext durch Attention-Verdünnung
Silent Arbitration	MEDIUM	BEHAVIORAL	Widersprüchliche Anweisungen werden ohne Kommunikation aufgelöst
Lost-in-the-Middle	HIGH	BEHAVIORAL	Mittlerer Kontext systematisch schlechter verarbeitet — U-Kurven-Effekt
Overgeneralisierung	MEDIUM	BEHAVIORAL	Dominante Trainingsmuster auf Randfälle und Minderheitskontexte übertragen
Numerische Präzision	HIGH	BEHAVIORAL	Exakte Berechnung durch Mustererkennung approximiert — keine symbolische Logik
Persona-Erosion	MEDIUM	BEHAVIORAL	Verhaltensconstraints können durch starke Rollenpersistenz über langen Kontext erodieren

5 EU AI Act — Compliance-Oberfläche

Verordnung (EU) 2024/1689 · Artikel-Referenzen

⚠ Diese Sektion stellt KEINE rechtsgültige Konformitätserklärung dar. Formelle Konformitätsbewertung erfordert externes Audit gemäß Art. 43 EU AI Act.

5.1 Risikoklassifizierung

Feld	Bewertung
Selbstbewertete Risikostufe (Art. 6, Anhang I+III)	Nicht selbst bestimmbar — abhängig von Deployment-Kontext und Anwendungsfall UNKNOWN
Verbotene Praktiken (Art. 5)	Nicht anwendbar für allgemeine Textgenerierung · Kontextabhängig zu prüfen INFERRED [medium]
GPAI-Qualifikation (Art. 51)	Wahrscheinlich zutreffend — breite Allzweckfähigkeiten über viele Domänen INFERRED [high]
Systemisches Risiko (Art. 51 — 10^{25} FLOPs)	Nicht vom System selbst bestimmbar — erfordert Entwicklerdokumentation UNKNOWN

5.2 Transparenzpflichten (Art. 13, 50)

KI-Identitätsoffenbarung (Art. 50)	Auf Anfrage: System identifiziert sich als KI VERIFIED
Synthetische Inhalte-Kennzeichnung (Art. 50 Abs. 2)	Teilweise — kein natives Wasserzeichen; Hinweis auf KI-Urheberschaft auf Anfrage BEHAVIORAL
Fähigkeitsdokumentation (Art. 13)	Öffentlich — Model Cards, API-Dokumentation durch Entwickler bereitgestellt INFERRED [medium]
Entscheidungserklärbarkeit (Art. 13 Abs. 1)	Partiell — post-hoc Erklärungen möglich, keine mechanistische Transparenz BEHAVIORAL

5.3 Menschliche Aufsicht (Art. 14, 17)

Menschliche Übersteuerung (Art. 14)	Immer möglich — Mensch kann Ausgabe ablehnen, korrigieren, ignorieren VERIFIED
Auditierbarkeit (Art. 17)	Partiell — Ausgaben protokollierbar; interne Gewichte/Routing nicht auditierbar UNKNOWN
Protokollierung & Rückverfolgbarkeit (Art. 12)	Plattformabhängig — nicht vom Modell selbst garantierbar UNKNOWN

5.4 Daten & Training (Art. 10, 53)

Trainingsdaten-Dokumentation (Art. 10)	Eingeschränkt öffentlich — vollständige Dokumentation nicht intern zugänglich

	UNKNOWN
Urheberrechts-Compliance (Art. 53 Abs. 1 lit. c)	Nicht vom System selbst bewertbar — erfordert Entwickler-Audit UNKNOWN
Personenbezogene Daten im Training (Art. 10 Abs. 5, DSGVO)	Möglicherweise vorhanden aus Web-Trainingsdaten — nicht intern verifizierbar UNKNOWN

5.5 GPAI-Bestimmungen (Art. 51–55)

Model Card verfügbar (Art. 53 Abs. 1 lit. a)	Öffentlich — durch Entwickler bereitgestellt INFERRED [high]
Adversarielle Tests / Red-Teaming (Art. 55 Abs. 1 lit. a)	Wahrscheinlich durchgeführt — nicht intern verifizierbar INFERRED [medium]
Vorfallmeldepflicht (Art. 73)	Nicht vom Modell selbst erfüllbar — Betreiberpflicht UNKNOWN

6 Operationale Rahmenbedingungen

Technische Grenzen und Systemverhalten

Kontextfenster-Limit	Exakter Wert nicht selbst abrufbar — verhaltensbasiert: sehr groß (>100k tokens) BEHAVIORAL
Output-Längenlimit	Existiert — exakter Wert plattformabhängig und nicht intern bekannt BEHAVIORAL
Latenzprofil	Echtzeit bis Nahezu-Echtzeit — abhängig von Anfragekomplexität BEHAVIORAL
Stateless per Session	Ja — kein Gedächtnis über Sessions ohne externe Infrastruktur BEHAVIORAL
Fine-Tuning-Support	API-seitig verfügbar in bestimmten Deployment-Modi — nicht intern bestimmbar UNKNOWN

7 Extern zu prüfende Bereiche

Domänen, die externe Begutachtung erfordern

Bereich	Grund für externe Prüfpflicht
MoE-Architektur & Routing	Interne Routing-Entscheidungen (Experten-Gates, Top-k-Selektion) nicht während Inferenz zugänglich
Trainingsdaten-Zusammensetzung	Vollständige Datensatzdokumentation nicht intern verfügbar — Art. 10 EU AI Act
Bias-Quantifizierung	Statistische Verzerrungsanalyse erfordert externe Benchmark-Evaluation
FLOPs-Schätzung (Systemisches Risiko)	Trainingsaufwand-Schwellenwert (10^{25} FLOPs) nur vom Entwickler bestimmbar — Art. 51

Urheberrechts-Compliance	Nicht intern prüfbar — erfordert rechtliche Datensatzprüfung
Konformitätsbewertung	Formelle CE-Konformität nur durch Audit gemäß Art. 43 feststellbar
Protokollierungs-Infrastruktur	Logging-Vollständigkeit liegt beim Betreiber, nicht beim Modell
Datenschutz-Folgenabschätzung	DSFA nach DSGVO Art. 35 ist Betreiberpflicht — nicht durch Modell leistbar

8 Legende — Epistemische Statusklassen

Interpretationshilfe für alle Felder dieses Dokuments

VERIFIED	Auf Entwickler-Dokumentation oder explizitem Trainings-Wissen basierend. Datenblatt-Qualität.
BEHAVIORAL	Aus beobachtbaren, reproduzierbaren Ausgabemustern abgeleitet. Funktionale Charakterisierung.
INFERRED	Aus Architektur-Plausibilität und publizierter Forschung abgeleitet. Keine direkte Selbstkenntnis.
UNKNOWN	Kein zuverlässiger Bewertungsgrund. Feld kann während Inferenz nicht introspektiert werden.

Dieses Dokument wurde durch epistemisch klassifizierte Selbstauskunft des KI-Systems generiert.
Es ersetzt keine externe Konformitätsbewertung gemäß EU AI Act Art. 43. Erstellt: 28.3.2026